

Retele bayesiene

IA 2025/2026

Conținut

Introducere

Inferență

Independență

Teorema lui Bayes

Rețele bayesiene

Inferență în rețele bayesiene


Introducere

- ▶ O rețea bayesiană modelează relații de dependență probabilistică între variabile
- ▶ Estimarea probabilității unui eveniment pe baza observațiilor
Modelarea unor procese cauzale (vreme → trafic → întarzieri)
Diagnostic medical (boala, simptome, teste)
Predictia comportamentului utilizatorilor, etc.

Probabilități

Probabilitatea asociată unei propoziții este suma probabilităților lumilor în care aceasta este adevărată.

$$P(\phi) = \sum_{w \in \phi} P(w), \quad \phi \text{ propoziție}$$



$P(A)$ is the area of the oval

Exemplu: $P(\text{Total} = 11) = P((5, 6)) + P((6, 5)) = 1/36 + 1/36 = 1/18.$

Presupunem $P(\text{doubles}) = 1/4$.


Probabilități necondiționate (prior)

Probabilități condiționate

Probabilități condiționate (*posterior*) $P(A|B)$ este fractiunea de lumi posibile în care B este adevărată și atunci și A este adevărată

- ▶ probabilitatea lui A , dat fiind B

$$P(a|b) = \frac{P(a \wedge b)}{P(b)}$$



Exemplu: $P(\text{doubles}|\text{Die}_1 = 5) = \frac{P(\text{doubles} \wedge \text{Die}_1=5)}{P(\text{Die}_1=5)}.$

Regula produs: $P(a \wedge b) = P(a|b)P(b)$

Probabilități

- Distribuție de probabilitate a unei variabile aleatoare **discrete**

$$P(\text{Weather} = \text{sunny}) = 0.6$$

$$P(\text{Weather} = \text{rain}) = 0.1$$

$$P(\text{Weather} = \text{cloudy}) = 0.29$$

$$P(\text{Weather} = \text{snow}) = 0.01$$

$$\mathbf{P}(\text{Weather}) = \langle 0.6, 0.1, 0.29, 0.01 \rangle$$

- Funcția densitate de probabilitate pentru a descrie distribuția unei var. aleatoare **continue**

$P(\text{NoonTemp} = x) = \text{Uniform}_{[18C, 26C]}(x)$ temperatura la prânz e distribuită uniform între 18C și 26C

$$P(x) = \lim_{dx \rightarrow 0} P(x \leq X \leq x + dx)/dx$$

Probabilități

- Distribuția comună de probabilitate: probabilitățile tuturor combinațiilor de valori ale var.

$P(Weather, Cavity)$: o tabela 4×2

Obs: în locul celor 8 ecuații, putem utiliza

$$P(Weather, Cavity) = P(Weather|Cavity)P(Cavity).$$

Full joint probability distribution: distribuția comună a tuturor variabilelor aleatoare

$Cavity, Toothache, Weather \rightarrow P(Cavity, Toothache, Weather)$

Exemplu: Distribuția comună de probabilitate

Variabilele bool. *Toothache*, *Cavity*, *Catch*; 3 variabile binare: $2^3 - 1 = 7$ parametri independenți;

Pentru n variabile booleene, tabela are dimensiunea $O(2^n)$.

		toothache		\neg toothache
	catch	\neg catch	catch	\neg catch
cavity	0.108	0.012	0.072	0.008
\neg cavity	0.016	0.064	0.144	0.576

$$P(cavity \vee toothache) = 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.28$$

Conținut

Introducere

Inferență

Independență

Teorema lui Bayes

Rețele bayesiene

Inferență în rețele bayesiene

Distribuție marginală

Distribuția marginală peste o var. / o submulțime de var.

- **Marginalizare:** însumăm probabilitățile pentru fiecare valoare posibilă a celorlalte variabile.

$$P(\mathbf{Y}) = \sum_{\mathbf{z} \in \mathbf{Z}} P(\mathbf{Y}, \mathbf{z})$$

Exemplu: $P(Cavity) = \sum_{\mathbf{z} \in \{Catch, Toothache\}} P(Cavity, \mathbf{z})$

Prob. marginală $P(cavity) = 0.108 + 0.012 + 0.072 + 0.008 = 0.2$

	toothache		¬toothache	
	catch	¬catch	catch	¬catch
cavity	0.108	0.012	0.072	0.008
¬cavity	0.016	0.064	0.144	0.576

- **Conditionare** $P(\mathbf{Y}) = \sum_{\mathbf{z}} P(\mathbf{Y}|\mathbf{z})P(\mathbf{z})$


Inferență

Inferență probabilistă: calculul probabilităților **condiționate**, date fiind anumite observații.

Procedura de **inferență**: fie variabila X , \mathbf{E} lista de variabile evidență, \mathbf{e} lista de valori observate, \mathbf{Y} variabile neobserve

$$\mathbf{P}(X|\mathbf{e}) = \alpha \mathbf{P}(X, \mathbf{e}) = \alpha \sum_{\mathbf{y}} \mathbf{P}(X, \mathbf{e}, \mathbf{y}) \quad (1)$$

Coefficient de normalizare



Probabilități condiționate: exemplu

		toothache		\neg toothache
	catch	\neg catch	catch	\neg catch
cavity	0.108	0.012	0.072	0.008
\neg cavity	0.016	0.064	0.144	0.576

$$P(\text{cavity}|\text{toothache}) = \frac{P(\text{cavity} \wedge \text{toothache})}{P(\text{toothache})} = \frac{0.108 + 0.012}{0.108 + 0.012 + 0.016 + 0.064} = 0.6$$

$$P(\neg\text{cavity}|\text{toothache}) = 0.4$$

$$\mathbf{P}(\text{Cavity}|\text{toothache}) = \alpha \mathbf{P}(\text{Cavity}, \text{toothache})$$

$$\begin{aligned} &= \alpha [\mathbf{P}(\text{Cavity}, \text{toothache}, \text{catch}) + \mathbf{P}(\text{Cavity}, \text{toothache}, \neg\text{catch})] \\ &= \alpha [\langle 0.108, 0.016 \rangle + \langle 0.012, 0.064 \rangle] = \alpha \langle 0.12, 0.08 \rangle = \langle 0.6, 0.4 \rangle \end{aligned}$$

Obs: $1/P(\text{toothache})$ const. de normalizare pentru distribuția $\mathbf{P}(\text{Cavity}|\text{toothache})$.

Conținut

Introducere

Inferență

Independență

Teorema lui Bayes


Rețele bayesiene

Inferență în rețele bayesiene

Independență

Variabilele X și Y sunt **independente**: $\mathbf{P}(X|Y) = \mathbf{P}(X)$ sau $\mathbf{P}(Y|X) = \mathbf{P}(Y)$ sau $\mathbf{P}(X, Y) = \mathbf{P}(X)\mathbf{P}(Y)$.

Exemplu: adăugăm variabila *Weather*.



Sunt necesare mai puține informații pentru a specifica distribuția comună de probabilitate. Distribuția comună poate fi *factorizată* în două distribuții.

Independență: exemplu

- ▶ $P(\text{toothache}, \text{catch}, \text{cavity}, \text{cloudy}) = P(\text{cloudy}|\text{toothache}, \text{catch}, \text{cavity})P(\text{toothache}, \text{catch}, \text{cavity})$ (regula produs)
- ▶ Obs: problemele dentare nu influențează vremea și invers
 $P(\text{cloudy}|\text{toothache}, \text{catch}, \text{cavity}) = P(\text{cloudy})$
independență (marginală, absolută)
- ▶ Deducem
 $P(\text{toothache}, \text{catch}, \text{cavity}, \text{cloudy}) = P(\text{cloudy})P(\text{toothache}, \text{catch}, \text{cavity})$
și
 $\mathbf{P}(\text{Toothache}, \text{Catch}, \text{Cavity}, \text{Weather}) = \mathbf{P}(\text{Toothache}, \text{Catch}, \text{Cavity})\mathbf{P}(\text{Weather})$

Conținut

Introducere

Inferență

Independență

Teorema lui Bayes

Rețele bayesiene

Inferență în rețele bayesiene

Teorema lui Bayes, '73

Utilizând regula produs:

$$P(a \wedge b) = P(a|b)P(b)$$

$$P(a \wedge b) = P(b|a)P(a)$$

→

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$

$$\mathbf{P}(Y|X) = \frac{\mathbf{P}(X|Y)\mathbf{P}(Y)}{\mathbf{P}(X)}$$

Teorema lui Bayes

$$\mathbf{P}(I|E) = \frac{\mathbf{P}(E|I)\mathbf{P}(I)}{\mathbf{P}(E)}$$

- ▶ I ipoteza, E evidență (provine din datele observate)
- ▶ $\mathbf{P}(I|E)$ probabilitatea **a posteriori** a ipotezei, dată fiind evidența (*posterior*)
- ▶ $\mathbf{P}(E|I)$ verosimilitatea (*likelihood*): măsura în care s-a observat evidența, în condițiile îndeplinirii ipotezei
- ▶ $\mathbf{P}(I)$ probabilitatea a priori (*prior*) (gradul de încredere în ipoteză)

Teorema lui Bayes

Cunoaștem evidența (efectul unei cauze necunoscute), și dorim să determinăm cauza:

$$P(\text{cause}|\text{effect}) = \frac{P(\text{effect}|\text{cause})P(\text{cause})}{P(\text{effect})}$$

Diagnostic medical: doctorul cunoaște $P(\text{symptoms}|\text{disease})$ și identifică diagnosticul $P(\text{disease}|\text{symptoms})$.

Exemplu: $P(s|m) = 0.7$ meningita cauzează înțepenirea gâtului în 70% din cazuri, $P(m) = 1/50000$, $P(s) = 0.01$.

$$P(m|s) = \frac{P(s|m)P(m)}{P(s)} = \frac{0.7 \cdot 1/50000}{0.01} = 0.0014$$

Teorema lui Bayes

Forma generală

$$\mathbf{P}(Y|X) = \alpha \mathbf{P}(X|Y) \mathbf{P}(Y)$$

α const de normalizare

Dacă avem **mai mult de o variabilă evidentă?**

- ▶ Dacă cunoaștem distribuția comună de probabilitate
 $P(Cavity|toothache \wedge catch) = \alpha \langle 0.108, 0.016 \rangle \approx \langle 0.871, 0.129 \rangle.$
- ▶ Utilizând teorema lui Bayes:

$$\begin{aligned} P(Cavity|toothache \wedge catch) &= \alpha \mathbf{P}(toothache \wedge catch|Cavity) \mathbf{P}(Cavity) \\ &= \alpha P(toothache|Cavity) P(catch|Cavity) P(Cavity) \end{aligned}$$

Independentă condiționată a *toothache* și *catch*, dat *Cavity*
(independente condiționat, dată prezența/absența cariei)

Teorema lui Bayes

Independentă condiționată a două variabile X și Y dat Z :

$$\mathbf{P}(X, Y|Z) = \mathbf{P}(X|Z)\mathbf{P}(Y|Z).$$

Exemplu:

$$\begin{aligned}\mathbf{P}(\text{Toothache}, \text{Catch}, \text{Cavity}) &= \mathbf{P}(\text{Toothache}, \text{Catch}|\text{Cavity})\mathbf{P}(\text{Cavity}) \\ &= \mathbf{P}(\text{Toothache}|\text{Cavity})\mathbf{P}(\text{Catch}|\text{Cavity})\mathbf{P}(\text{Cavity})\end{aligned}$$

Pentru n simptome indep cond, dat Cavity , dimensiunea reprezentării crește liniar.

$$\mathbf{P}(\text{Cause}, \text{Effect}_1, \dots, \text{Effect}_n) = \mathbf{P}(\text{Cause}) \prod_i \mathbf{P}(\text{Effect}_i|\text{Cause})$$

(modelul *Naive Bayes*)

Independență și independentă condiționată

Exemplul 1. Ion (A) și Maria (B) dau cu banul de 100 de ori. Fiecare are un ban diferit.

- ▶ evenimente independente

$$P(A|B) = P(A), P(B|A) = P(B)$$

Rezultatul unui experiment nu influențează rezultatul celuilalt experiment.

Exemplul 2. Ion și Maria dau cu același ban

- ▶ dacă banul nu este corect, evenimentul A (Ion) poate aduce informații asupra evenimentului B (Maria)
- ▶ evenimentele **nu sunt independente**

Independență și independentă condiționată

Exemplul 3. Ion și Maria locuiesc în zone diferite ale orașului și vin la serviciu cu tramvaiul, respectiv mașina

- ▶ "Ion a întârziat" și "Maria a întârziat" pot fi considerate independente
- ▶ dacă vatmanii sunt în grevă, atunci și traficul rutier crește; evenimentele sunt **independente condiționat**

Conținut

Introducere

Inferență

Independență


Teorema lui Bayes

Rețele bayesiene

Inferență în rețele bayesiene

Rețele bayesiene

- ▶ Modele grafice probabilistice care reprezintă dependențele între variabile
- ▶ Reprezentarea informațiilor legate de evenimente probabilistice ne va ajuta să realizăm eficient **răționamente**
- ▶ Aplicații: sisteme pentru diagnostic medical, estimarea caracteristicilor psihologice din teste, modelarea mediului (populațiile de urși polari), etc.




Rețea bayesiană

Este un digraf aciclic

- ▶ fiecare nod corespunde unei variabile aleatoare (eveniment)
- ▶ un arc de la X la Y (X este părintele lui Y): X are o influență directă asupra lui Y
- ▶ fiecare nod X_i are o distribuție de probabilitate condiționată $\mathbf{P}(X_i | \text{Parents}(X_i))$ (efectul părintilor asupra nodului)


Topologia rețelei specifică relațiile de independentă condiționată:



Toothache și *Catch* sunt independente condiționat, dat *Cavity*.

Rețele bayesiene: exemplu

Un sistem de alarmă care sună în cazul unei spargeri, dar și în cazul unui cutremur. Vecinii John și Mary îl sună pe proprietar la serviciu dacă aud alarma.




Efracțiile și cutremurile afectează probabilitatea declanșării alarmei. Alarma influențează probabilitatea ca John și Mary să sune.

Dorim să estimăm probabilitatea unei spargeri, în funcție de cine a sunat.

Rețele bayesiene: exemplu

Cancerul metastatic este o cauză posibilă a tumorilor cerebrale și este de asemenea, o explicație pentru creșterea calciului seric total. Oricare dintre acestea ar putea explica intrarea unui pacient în comă. Cefaleea severă este, de asemenea, asociată cu tumorile cerebrale.



Obs: alăturat avem **tabelele de probabilitate condiționată**.

Interogări simple

O conjuncție $P(X_1 = x_1 \wedge \dots \wedge X_n = x_n)$

Presupunerea modelului bazat pe rețele bayesiene este că o variabilă nu depinde decât de părintii săi:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | parents(X_i)) \quad (2)$$

Exemplu: probabilitatea declansării alarmei, când nu a fost o spargere sau un cutremur, iar John și Mary au sunat

$$\begin{aligned} P(j, m, a, \neg b, \neg e) &= P(j|a)P(m|a)P(a|\neg b \wedge \neg e)P(\neg b)P(\neg e) \\ &= 0.90 \cdot 0.70 \cdot 0.001 \cdot 0.999 \cdot 0.998 = 0.000628 \end{aligned}$$

Construcția unei rețele bayesiene

Utilizăm *regula produs* pentru a rescrie distribuția comună de probabilitate:

$$\begin{aligned} P(x_1, \dots, x_n) &= P(x_n | x_{n-1}, \dots, x_1)P(x_{n-1}, \dots, x_1) \\ &= P(x_n | x_{n-1}, \dots, x_1)P(x_{n-1} | x_{n-2}, \dots, x_1) \dots P(x_2 | x_1)P(x_1) \\ &= \prod_{i=1}^n P(x_i | x_{i-1}, \dots, x_1) \end{aligned}$$

(Regula de înmulțire a probabilităților (chain rule))

$$\mathbf{P}(X_i | X_{i-1}, \dots, X_1) = \mathbf{P}(X_i | \text{Parents}(X_i)) \quad (3)$$

$\forall X_i$ variabilă din rețea, cu condiția $\text{Parents}(X_i) \subseteq \{X_{i-1}, \dots, X_1\}$.

Rețeaua bayesiană este o reprezentare corectă dacă fiecare nod este independent condiționat de predecesorii din ordonare, dați fiind părintii.

Construcția unei rețele bayesiene

- ▶ Determină mulțimea de variabile $\{X_1, \dots, X_n\}$. Ordonează variabilele a.i. cauzele preced efectele.
- ▶ Pentru $i = 1, \dots, n$
 - ▶ alege din X_1, \dots, X_{i-1} o mulțime minimală de părinti a.i. ecuația (3) este satisfacută
 - ▶ pentru fiecare părinte, inserează un arc de la acesta la X_i
 - ▶ adaugă tabela de probabilitate condiționată $P(X_i | Parents(X_i))$

Exemplu:

$P(MaryCalls | JohnCalls, Alarm, Earthquake, Burglary) = P(MaryCalls | Alarm)$,
rezultă *Alarm* este singurul părinte al *MaryCalls*

Sortarea topologică


- ▶ Sortarea topologică a unui digraf este o ordonare liniară a nodurilor a.i. $\forall A \rightarrow B$, A apare înaintea lui B .
- ▶ Pentru o rețea bayesiană, sortarea topologică asigură faptul că părintii vor apărea înaintea fiilor.
- ▶ Dacă graful este orientat aciclic, există cel puțin o soluție; dacă există cicluri, sortarea topologică nu este posibilă.

Sortare topologică: algoritmul lui Kahn

```
L ← Empty list that will contain the sorted elements  
S ← Set of all nodes with no incoming edge
```

```
while S is not empty do  
    remove a node n from S  
    add n to L  
    for each node m with an edge e from n to m do  
        remove edge e from the graph  
        if m has no other incoming edges then  
            insert m into S  
  
if graph has edges then  
    return error (graph has at least one cycle)  
else  
    return L (a topologically sorted order)
```

Complexitate timp: $O(n + m)$, n noduri, m arce



1. $L = \emptyset, S = \{G, A\}$
2. $L = \{G\}, S = \{A\}$
3. elimină (GF)
 F nu poate fi adăugat în S : $\exists(AF)$
4. $L = \{G, A\}, S = \emptyset$
5. elimină (AF) , $S = \{F\}$
6. $L = \{G, A, F\}, S = \emptyset$
7. elimină (FO) , $S = \{O\}$, ...
 $\rightarrow L = \{G, A, F, O, X\}$

Rețele bayesiene: avantaje reprezentare


n variabile, fiecare influențată de cel mult k variabile $\rightarrow 2^k$ (pentru a specifica o tabelă de probabilitate condiționată) $\rightarrow n2^k$
vs.

Distribuția comună: 2^n

Exemplu: $n=30$ noduri, $k = 5$ părinti $\rightarrow 960$ vs. 10^9 .

Independență condiționată

- ▶ Fiecare variabilă este independentă condiționat de ne-descendenți, dați părintii.



JohnCalls este independent de *Burglary*, *Earthquake*, *MarryCalls*, dat *Alarm*.

- ▶ **Markov blanket**: un nod e independent condiționat de celălalte noduri, dați părintii, copiii și părintii copiilor

Burglary este independent de *JohnCalls* și *MaryCalls*, dat *Alarm* și *Earthquake*

Conținut

Introducere

Inferență

Independență

Teorema lui Bayes


Rețele bayesiene

Inferență în rețele bayesiene

Inferența probabilităților marginale

- ▶ Calculează probabilitățile nodurilor, în **lipsa unor noduri evidență**
- ▶ Pentru un nod: calculăm suma **probabilităților condiționate**, înmulțite cu **probabilitățile părintilor** (toate combinațiile posibile de valori ale părintilor).

Inferența probabilităților marginale: exemplu



$P(Gripă = Da)$	$P(Gripă = Nu)$
0,1	0,9

$P(Abces = Da)$	$P(Abces = Nu)$
0,05	0,95

$Gripă$	$Abces$	$P(Febră = Da)$	$P(Febră = Nu)$
Da	Da	0,8	0,2
Da	Nu	0,7	0,3
Nu	Da	0,25	0,75
Nu	Nu	0,05	0,95

$Febră$	$P(Oboseală = Da)$	$P(Oboseală = Nu)$
Da	0,6	0,4
Nu	0,2	0,8

$Febră$	$P(Anorexie = Da)$	$P(Anorexie = Nu)$
Da	0,5	0,5
Nu	0,1	0,9

$$\begin{aligned}P(f) &= P(f|g, a)P(g)P(a) + P(f|g, \neg a)P(g)P(\neg a) \\&\quad + P(f|\neg g, a)P(\neg g)P(a) + P(f|\neg g, \neg a)P(\neg g)P(\neg a) \\&= 0.8 \cdot 0.1 \cdot 0.05 + 0.7 \cdot 0.1 \cdot 0.95 + 0.25 \cdot 0.9 \cdot 0.05 + 0.05 \cdot 0.9 \cdot 0.95 \\&= 0.1245\end{aligned}$$

$$P(\neg f) = 1 - P(f) = 0.8755$$


Exemplu: Oboseală și Anorexie

$$\begin{aligned}P(o) &= P(o|f)P(f) + P(o|\neg f)P(\neg f) \\&= 0.6 \cdot 0.1245 + 0.2 \cdot 0.8755 = 0.25\end{aligned}$$

$$P(\neg o) = 1 - P(o) = 0.75$$

$$\begin{aligned}P(x) &= P(x|f)P(f) + P(x|\neg f)P(\neg f) \\&= 0.5 \cdot 0.1245 + 0.1 \cdot 0.8755 = 0.15\end{aligned}$$

$$P(\neg x) = 1 - P(x) = 0.85$$



Inferență în rețele bayesiene

- ▶ Sistem de **inferență probabilist**: calculăm distribuția de probabilitate a posteriori pentru o mulțime de variabile, dat un eveniment
- ▶ X variabilă, \mathbf{E} mulțimea de variabile evidență E_1, \dots, E_m , \mathbf{e} eveniment, \mathbf{Y} non-evidență, Y_1, \dots, Y_l variabile ascunse

Distribuția de probabilitate a posteriori $P(X|\mathbf{e}) = ?$

Exemplu: observăm evenimentul în care $JohnCalls = true$ și

$MaryCalls = true$; atunci probabilitatea unei efracții:

$$P(Burglary|JohnCalls = true, MaryCalls = true) = \langle 0.284, 0.716 \rangle.$$

Inferență prin enumerare


$$\mathbf{P}(X|e) = \alpha \mathbf{P}(X, e) = \alpha \sum_y \mathbf{P}(X, e, y) \quad (1)$$

O rețea bayesiană oferă o reprezentare a **distribuției comune**.

Conform ecuației (2), termenul $\mathbf{P}(X, e, y)$ poate fi scris ca produs de probabilități condiționate.

Inferență prin enumerare: exemplu

Interogare: Care este probabilitatea unei efracții atunci când John și Mary sună? $P(\text{Burglary} | \text{JohnCalls} = \text{true}, \text{MaryCalls} = \text{true})$



Inferență prin enumerare: exemplu

$$P(\text{Burglary} | \text{JohnCalls} = \text{true}, \text{MaryCalls} = \text{true}) = ?$$

- Variabilele ascunse sunt *Earthquake* și *Alarm*.

$$\mathbf{P}(B|j, m) = \alpha \mathbf{P}(B, j, m) = \alpha \sum_e \sum_a \mathbf{P}(B, j, m, e, a)$$

- Pentru *Burglary* = true:

Conform ecuației (2):

$$P(b|j, m) = \alpha \sum_e \sum_a P(b)P(e)P(a|b, e)P(j|a)P(m|a)$$

Termenul $P(b)$ const, $P(e)$ nu depinde de a :

$$\begin{aligned} P(b|j, m) &= \alpha P(b) \sum_e P(e) \sum_a P(a|b, e)P(j|a)P(m|a) \\ &= \alpha P(b) \sum_e P(e)[P(a|b, e)P(j|a)P(m|a) + \\ &\quad P(\neg a|b, e)P(j|\neg a)P(m|\neg a)] \\ &= \dots \\ &= \alpha \times 0.00059224 \end{aligned}$$

Inferență prin enumerare: exemplu

Pentru $Burglary = false$, conform ecuației (2):

$$\begin{aligned} P(\neg b|j, m) &= \alpha \sum_e \sum_a P(\neg b)P(e)P(a|\neg b, e)P(j|a)P(m|a) \\ &= \dots \\ &= \alpha \times 0.0014919 \end{aligned}$$

$$P(b|j, m) + P(\neg b|j, m) = 1 \rightarrow \alpha = 479.8142$$

$$P(B|j, m) = \alpha \langle 0.00059224, 0.0014919 \rangle \approx \langle 0.284, 0.716 \rangle.$$


Probabilitatea unei spargeri: 28%.

Obs: pentru a eficientiza calculul, se recomandă ca **variabilele rămase** să fie mai întâi **sortate topologic**, a.i. părintii să apară înaintea copiilor.

În acest caz, se vor putea descompune mai ușor sumele, scoțând în față factorii care nu depind de o anumită variabilă.

Exemplu

Procesul de evaluare:



Algoritmul evaluează arborii de expresii în manieră DFS.

Complexitatea spațiu: $O(n)$, n variabile. Complexitatea timp: $O(2^n)$ pentru o rețea cu n variabile bool.

Algoritmul de eliminare a variabilelor (*variable elimination*)

- ▶ Obs: $P(j|a)P(m|a)$ și $P(j|\neg a)P(m|\neg a)$ sunt calculate de două ori, pentru fiecare valoare a lui e .
- ▶ Idee: realizează calculele de la dreapta către stânga (de jos în sus) și salvează rezultatele.

Variable elimination: exemplu

$$P(B|j, m) = \alpha \underbrace{P(b)}_{f_1(B)} \sum_e \underbrace{P(e)}_{f_2(E)} \sum_a \underbrace{P(a|B, e)}_{f_3(A, B, E)} \underbrace{P(j|a)}_{f_4(A)} \underbrace{P(m|a)}_{f_5(A)}$$

- ▶ Fiecare factor f_i este o matrice indexată de variabilele argument:
 $f_4(A) = \begin{pmatrix} P(j|a) \\ P(j|\neg a) \end{pmatrix} = \begin{pmatrix} 0.90 \\ 0.05 \end{pmatrix}$, $f_5(A) = \begin{pmatrix} P(m|a) \\ P(m|\neg a) \end{pmatrix} = \begin{pmatrix} 0.70 \\ 0.01 \end{pmatrix}$.
 $f_3(A, B, E)$ este o matrice $2 \times 2 \times 2$.
 f_4 depinde doar de A deoarece *MaryCalls = true*.

$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$$

Variable elimination: exemplu

$$\begin{aligned}f_6(B, E) &= \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A) \\&= f_3(a, B, E) \times f_4(a) \times f_5(a) + f_3(\neg a, B, E) \times f_4(\neg a) \times f_5(\neg a)\end{aligned}$$

$$\begin{aligned}f_7(B) &= \sum_e f_2(E) \times f_6(B, E) \\&= f_2(e) \times f_6(B, e) + f_2(\neg e) \times f_6(B, \neg e)\end{aligned}$$

$$P(B|j, m) = \alpha f_1(B) \times f_7(B)$$

Inferență aproximativă

- ▶ Algoritmii exacti nu pot fi aplicati pentru **rețelele complexe**, cu sute de noduri. **Inferență aproximativă** poate crește viteza de calcul.
- ▶ Algoritmi de eșantionare aleatoare (**sampling**) pentru calculul **probabilităților condiționate**: *Rejection sampling, Likelihood weighting*.
 - ▶ eșantionăm dintr-o distribuție N eșantioane
 - ▶ aproximăm probabilitatea a posteriori \hat{P} (converge la probabilitatea adevărată P)

Prior sampling

Pentru a genera un eveniment particular:

```
function PRIOR-SAMPLE(bn) returns an event sampled from the prior specified by bn
  inputs: bn, a Bayesian network specifying joint distribution  $\mathbf{P}(X_1, \dots, X_n)$ 
  x  $\leftarrow$  an event with n elements
  foreach variable  $X_i$  in  $X_1, \dots, X_n$  do
     $x[i] \leftarrow$  a random sample from  $\mathbf{P}(X_i | parents(X_i))$ 
  return x
```

Probabilitatea de a genera un eveniment particular:

$$S_{PS}(x_1 \dots x_n) = \prod_{i=1} P(x_i | parents(X_i)) = P(x_1 \dots x_n)$$

Prior sampling: exemplu

Considerăm ordonarea *Cloudy, Sprinkler, Rain, WetGrass*.


Eșantionăm din $\mathbf{P}(\text{Cloudy}) = \langle 0.5, 0.5 \rangle$ valoarea *true*.

Eșantionăm din $\mathbf{P}(\text{Sprinkler}|\text{Cloudy} = \text{true}) = \langle 0.1, 0.9 \rangle$ valoarea *false*.

Eșantionăm din $\mathbf{P}(\text{Rain}|\text{Cloudy} = \text{true}) = \langle 0.8, 0.2 \rangle$ valoarea *true*.

Eșantionăm din

$\mathbf{P}(\text{WetGrass}|\text{Sprinkler} = \text{false}, \text{Rain} = \text{true}) = \langle 0.9, 0.1 \rangle$ valoarea *true*.



$$S_{PS}(t, f, t, t) = 0.5 \times 0.9 \times 0.8 \times 0.9 = 0.324 = P(t, f, t, t)$$

Fie $N_{PS}(x_1 \dots x_n)$ nr. de eșantioane generate pentru evenimentul x_1, \dots, x_n .

$$\begin{aligned}\lim_{N \rightarrow \infty} \hat{P}(x_1, \dots, x_n) &= \lim_{N \rightarrow \infty} N_{PS}(x_1, \dots, x_n)/N \\ &= S_{PS}(x_1, \dots, x_n) \\ &= P(x_1 \dots x_n)\end{aligned}$$

Rejection sampling

- ▶ generăm eșantioane din distribuția apriori
Dacă în 511 eșantioane din 1000 'Rain=true', atunci $\hat{P}(Rain = true) = 0.511$.
- ▶ respingem eșantioanele care nu se potrivesc cu evidența
- ▶ estimăm $\hat{P}(X = x|e)$

$$\hat{P}(X|e) = \alpha N_{PS}(X, e) = \frac{N_{PS}(X, e)}{N_{PS}(e)}$$

Exemplu: estimăm $\mathbf{P}(Rain|Sprinkler = true)$

Din 100 eșantioane generate, 73 au 'Sprinkler = false' (respinse) și 27 au 'Sprinkler = true'; din cele 27, 8 au 'Rain = true' și 19 'Rain = false'.

$$\mathbf{P}(Rain|Sprinkler = true) \approx \text{NORMALIZE}(< 8, 19 >) = < 0.296, 0.704 >$$

Rejection sampling

```
function REJECTION-SAMPLING( $X, \mathbf{e}, bn, N$ ) returns an estimate of  $\mathbf{P}(X|\mathbf{e})$ 
    inputs:  $X$ , the query variable
     $\mathbf{e}$ , observed values for variables  $\mathbf{E}$ 
     $bn$ , a Bayesian network
     $N$ , the total number of samples to be generated
    local variables:  $\mathbf{N}$ , a vector of counts for each value of  $X$ , initially zero

    for  $j = 1$  to  $N$  do
         $\mathbf{x} \leftarrow$  PRIOR-SAMPLE( $bn$ )
        if  $\mathbf{x}$  is consistent with  $\mathbf{e}$  then
             $\mathbf{N}[x] \leftarrow \mathbf{N}[x]+1$  where  $x$  is the value of  $X$  in  $\mathbf{x}$ 
    return NORMALIZE( $\mathbf{N}$ )
```

Dezavantaj: multe eșantioane sunt respinse (nr. de eșantioane consistente scade exponențial cu nr. de var. evidență)

Bibliografie

- ▶ S. Russell, P. Norvig. *Artificial Intelligence: A Modern Approach*. Ch. 13. Quantifying Uncertainty; Ch. 14. Probabilistic Reasoning
- ▶ Belief and Decision Networks <https://aispace.org/bayes/>